



DOSSIER DE SYNTHÈSE

Preuve de concept — Prédiction des tendances électorales

Projet Electio-Analytics — Région Bretagne

MSPR TPRE813 — Big Data et Analyse de données

Bloc 3 — Piloter l'informatique décisionnel d'un S.I.

Certification Expert en Informatique et Système d'Information (RNCP 35584)

Équipe projet : Thanina YATAGHANE & Dalia OUDJANI

Date de remise : 16/06/2026

Date de soutenance : 19/06/2026

Sommaire

<u>1. Introduction et contexte</u>	4
<u>2. Justification du choix de la zone géographique</u>	4
<u>3. Choix et justification des indicateurs</u>	8
<u>4. Démarche générale et architecture</u>	8
<u>5. Collecte et préparation des données (ETL)</u>	10
<u>6. Modèle conceptuel de données et base SQL</u>	11
<u>7. Analyse exploratoire et visualisations</u>	12
<u>8. Modélisation prédictive</u>	16
<u>9. Scénarios prédictifs</u>	23
<u>10. Réponses aux questions d'analyse</u>	28
<u>11. Limites et perspectives</u>	29
<u>12. Conclusion</u>	30

Liste des figures

Figure 1 : Taux de participation au 1er tour de la présidentielle - Bretagne vs France entière.

Figure 2 : Résultats du 1er tour de la présidentielle 2022 par département breton.

Figure 3 : Nombre de communes par région française (2022).

Figure 4 : Évolution du taux d'abstention au 1er tour de la présidentielle en Bretagne (2007-2022).

Figure 5 : Schéma de flux du pipeline de traitement des données.

Figure 6 : Modèle Conceptuel de Données (MCD) de la base `electio_analytics.db`.

Figure 7 : Carte du groupe politique gagnant par commune — Bretagne, 2017 vs 2022.

Figure 8 : Évolution des scores moyens par groupe politique — Bretagne, 2017 vs 2022.

Figure 9 : Nombre de communes gagnées par groupe politique — Bretagne, 2017 vs 2022.

Figure 10 : Matrice de corrélation entre indicateurs socio-économiques et scores politiques.

Figure 11 : Indicateur le plus corrélé pour chaque groupe politique.

Figure 12 : Distribution du revenu médian par commune.

Figure 13 : Matrices de confusion des 5 modèles testés (jeu de test).

Figure 14 : Courbes d'apprentissage des 5 modèles testés.

Figure 15 : Courbes precision-recall (one-vs-rest) des 5 modèles testés.

Figure 16 : Courbe de perte (log-loss) du modèle Gradient Boosting.

Figure 17 : Importance des variables — Random Forest et Gradient Boosting.

Figure 18 : Synthèse comparative des 5 modèles (accuracy, F1 macro, validation croisée).

Figure 19 : Matrice de confusion du modèle final — Régression Logistique (jeu de test).

Figure 20 : Distribution des probabilités prédites par groupe politique.

Figure 21 : Carte de chaleur — probabilité prédite de victoire de l'extrême droite, par commune.

Figure 22 : Évolution du pourcentage de communes gagnées par groupe — réel vs modèle.

Figure 23 : Carte comparative : résultat réel vs prédiction du modèle — 2022.

Figure 24 : Scénario de projection à 1, 2 et 3 ans (accentuation progressive de la tendance observée).

1. Introduction et contexte

Electio-Analytics est une start-up de conseil stratégique dédiée aux campagnes électorales. Elle accompagne candidats, partis et cabinets de conseil en leur fournissant des analyses prospectives fondées sur l'exploitation de données publiques et privées. Son besoin stratégique est de se doter d'une capacité de prévision des tendances électorales à moyen terme (un à trois ans), à partir d'indicateurs socio-économiques tels que la sécurité, l'emploi, la démographie, la vie économique ou la pauvreté.

Avant d'engager des investissements importants, l'entreprise souhaite valider cette approche par une preuve de concept (POC), conçue sur un périmètre géographique restreint et unique. La présente mission, confiée à notre société de service, consiste à concevoir cette preuve de concept : collecter et structurer les données, construire un modèle prédictif fiable, restituer les résultats sous forme de visualisations exploitables, et documenter l'ensemble de la démarche de façon reproductible.

Ce dossier présente l'intégralité du travail réalisé : le choix du périmètre et des indicateurs, la chaîne de traitement des données (ETL), le modèle de données, l'analyse exploratoire, la modélisation prédictive, les scénarios de restitution, ainsi que les réponses aux questions d'analyse posées par le client.

2. Justification du choix de la zone géographique

Le périmètre retenu est la région Bretagne (4 départements : Côtes-d'Armor, Finistère, Ille-et-Vilaine, Morbihan). Ce choix répond aux trois critères demandés par le client : disponibilité, représentativité, taille exploitable complétés par un quatrième argument lié à la pertinence du cas d'étude.

Disponibilité et fiabilité des données

La Bretagne affiche un taux de participation systématiquement supérieur à la moyenne nationale sur les cinq dernières élections présidentielles. Une forte participation garantit des données électorales complètes et fiables : un nombre élevé de votants par commune limite les effets de petits échantillons et la sensibilité du résultat à quelques voix.

Taux de participation au 1er tour de la présidentielle — Bretagne vs France entière

Source : Ministère de l'Intérieur — archives-resultats-elections.interieur.gouv.fr




Figure 1 — Taux de participation au 1er tour de la présidentielle — Bretagne vs France entière.

Représentativité

Les résultats du 1er tour 2022, comparés entre les 4 départements bretons, montrent des nuances perceptibles selon les territoires (le Morbihan se distingue par exemple sur l'extrême droite par rapport aux Côtes-d'Armor). Cette variance, même modérée, est nécessaire : un territoire électoralement homogène ne donnerait au modèle aucune variation à apprendre.

Résultats 1er tour présidentielle 2022 par département breton

Source : Ministère de l'Intérieur — archives-resultats-elections.interieur.gouv.fr




Figure 2 — Résultats du 1er tour de la présidentielle 2022 par département breton.

Taille exploitable

Avec environ 1 200 communes, la Bretagne se situe dans la partie basse du classement des régions françaises (proche de l'Île-de-France ou des Pays de la Loire), loin des plus de 4 000 communes du Grand Est ou d'Auvergne-Rhône-Alpes. C'est un volume suffisant pour constituer un dataset exploitable (plusieurs centaines de communes pour l'entraînement et le test d'un modèle de classification), tout en restant gérable en temps et en ressources pour un POC.

Nombre de communes par région française — 2022

Source : Wikipedia — Nombre de communes en France, données INSEE 2022




Figure 3 — Nombre de communes par région française (2022).

Pertinence du cas d'étude : un comportement électoral évolutif

L'abstention en Bretagne a augmenté de façon continue, passant d'environ 12 % en 2007 à plus de 21 % en 2022, preuve que le comportement électoral breton évolue dans le temps, et n'est pas figé. C'est précisément ce type de dynamique que notre modèle cherche à relier aux indicateurs socio-économiques (via les variables de tendance / delta, cf. section 8.1), plutôt que de se baser sur une simple photographie statique. Cette évolution se confirme d'ailleurs dans nos résultats : la bascule électorale observée entre 2017 et 2022 fait de la Bretagne un terrain particulièrement pertinent pour tester la capacité d'un modèle prédictif à détecter de véritables tendances.

Évolution du taux d'abstention au 1er tour de la présidentielle en Bretagne (2007-2022)

Source : Ministère de l'Intérieur — archives-resultats-elections.interieur.gouv.fr




Figure 4 — Évolution du taux d'abstention au 1er tour de la présidentielle en Bretagne (2007-2022).

3. Choix et justification des indicateurs

Les indicateurs retenus comme variables explicatives ont été sélectionnés pour leur pertinence supposée vis-à-vis du comportement électoral, conformément aux pistes proposées par le client, et complétés par des variables dont la littérature et l'analyse exploratoire confirment le pouvoir discriminant. Ils couvrent six dimensions :

- **Emploi** : taux de chômage de la commune.
- **Éducation** : part de la population sans diplôme et part de diplômés de l'enseignement supérieur.
- **Niveau de vie** : revenu médian des habitants.
- **Sécurité** : taux de criminalité.
- **Démographie** : population et densité.
- **Activité économique et vie associative** : nombre d'entreprises pour mille habitants et nombre d'associations pour mille habitants.

Comme le détaille l'analyse exploratoire (section 7), ces indicateurs présentent des corrélations significatives avec les résultats électoraux. Le revenu médian s'avère le facteur le plus discriminant globalement (corrélation de +0,66 avec le score du centre, la plus forte de l'analyse), tandis que le niveau de diplôme se révèle particulièrement déterminant pour plusieurs groupes politiques (gauche, droite, extrême droite), ce qui justifie a posteriori la sélection de ces deux familles d'indicateurs.

4. Démarche générale et architecture

La démarche suit une logique industrielle, organisée en une chaîne de traitement reproductible. Les données brutes sont d'abord consolidées par un pipeline ETL en un jeu de données unique, qui alimente ensuite deux usages parallèles : d'une part une base de données structurée et l'analyse exploratoire, d'autre part la modélisation prédictive et la production de scénarios.

Étape	Description
Données brutes	13 fichiers sources (INSEE, data.gouv.fr) : résultats électoraux, population, diplômes, revenu, criminalité, entreprises, vie associative, géographie.
ETL	Nettoyage, normalisation et fusion en un jeu de données unique (dataset_bretagne.csv, 2 440 lignes).
Base SQL	Structuration en 4 tables (electio_analytics.db) conformes au modèle conceptuel de données.
Analyse exploratoire	Cartes, corrélations, distributions des indicateurs.
Modélisation ML	Mise au format large, comparaison de 5 modèles, sélection du modèle final.
Scénarios	Restitution : diagrammes de probabilité, cartes de chaleur, courbes temporelles, projection à 1/2/3 ans.

L'ensemble du code source, des notebooks et de la documentation est disponible sur le dépôt GitHub du projet : <https://github.com/nina296/electio-analytics-bretagne>, garantissant la transférabilité et la reproductibilité de la démarche.

Cette architecture garantit la traçabilité et la reproductibilité : chaque étape produit un livrable réutilisable, et l'ensemble peut être rejoué de bout en bout.




Figure 5 — Schéma de flux du pipeline de traitement des données.

5. Collecte et préparation des données (ETL)

Le pipeline ETL automatise la construction du jeu de données. Les fichiers électoraux des présidentielles 2017 et 2022 sont chargés, filtrés sur les communes bretonnes, et les scores des candidats sont regroupés par groupe politique (extrême gauche, gauche, centre, droite, extrême droite) afin de déterminer le groupe arrivé en tête dans chaque commune. Les indicateurs socio-économiques sont ensuite extraits de leurs sources respectives, puis l'ensemble est fusionné en un tableau unique comportant une ligne par commune et par année (2 440 lignes = 1 233 communes en 2017 + 1 207 communes en 2022).

5.1. Alignement temporel des indicateurs

Les indicateurs sont disponibles en deux millésimes, 2016 et 2021. Pour que chaque indicateur reflète la situation antérieure au vote, les valeurs de 2016 sont associées au scrutin de 2017 et celles de 2021 au scrutin de 2022. Cet alignement évite d'expliquer un vote par des données qui lui sont postérieures.

Un point méthodologique particulier concerne les indicateurs de diplôme : une attention spécifique a été portée pour garantir une nomenclature cohérente entre 2016 et 2021 (catégories “sans diplôme ou BEPC” et “diplôme de l'enseignement supérieur, Bac+2 et plus” calculées de façon identique sur les deux millésimes, à partir des bases INSEE “Diplômes-Formation” agrégées au niveau communal).

5.2. Exclusion des variables de fuite de données

Le groupe gagnant d'une commune pour une année donnée est déterminé par construction comme le groupe ayant obtenu le score le plus élevé cette même année. Utiliser les scores 2022 comme variables d'entrée pour prédire le gagnant 2022 reviendrait donc à fournir au modèle la réponse elle-même (fuite de données).

Ces colonnes ont par conséquent été exclues des variables explicatives pour la prédiction de 2022, de même que le nombre de votants / inscrits et les identifiants administratifs. En revanche, les scores de 2017 (élection précédente, antérieure à la cible) sont conservés comme variable explicative légitime : ils ne déterminent pas le résultat de 2022 et constituent une information disponible avant le scrutin prédit.

6. Modèle conceptuel de données et base SQL

Le jeu de données a été structuré dans une base SQLite (electio_analytics.db), choisie pour sa simplicité de déploiement (fichier unique portable, aucune installation) adaptée à un POC, avec migration vers PostgreSQL envisageable en production.




Figure 6 — Modèle Conceptuel de Données (MCD) de la base electio_analytics.db.

Table	Clé primaire	Principaux attributs	Lignes
commune	code_insee	nom, département, superficie, densité	1 233
indicateurs	id_indicateur	année, chômage, revenu, criminalité, diplômes, entreprises, vie associative	2 440
resultat_electoral	id_resultat	année, inscrits, votants, abstention, scores par groupe	2 440
groupe_politique	id_groupe	nom du groupe, candidats 2017 et 2022	5

Les relations principales sont : un résultat électoral est remporté par un groupe politique (un groupe peut remporter plusieurs communes / années), et une commune génère plusieurs jeux d'indicateurs et plusieurs résultats électoraux selon les années (relation 1, N). Cette modélisation, pleinement normalisée (pas de redondance, intégrité référentielle par clés étrangères), répond à l'exigence du cahier des charges d'un jeu de données nettoyé, normalisé et optimisé.

7. Analyse exploratoire et visualisations

L'analyse exploratoire vise à comprendre la structure des données et à identifier les relations entre indicateurs et résultats électoraux avant la modélisation.

7.1 Carte des résultats 2017 vs 2022

Carte du groupe politique gagnant par commune - Bretagne




Figure 7 — Carte du groupe politique gagnant par commune — Bretagne, 2017 vs 2022.

La carte comparative montre une bascule électorale majeure : la zone dominée par l'extrême droite, déjà présente à l'est en 2017, s'étend largement sur l'ensemble du territoire en 2022, au détriment notamment de la gauche.

7.2 Évolution des scores moyens par groupe




Figure 8 — Évolution des scores moyens par groupe politique — Bretagne, 2017 vs 2022.

Le score moyen d'extrême droite passe de 25,2 % à 33,5 % (+8,3 points), tandis que le groupe "droite" s'effondre de 18,5 % à 4,6 %. Centre (26,4 %→30,9 %) et gauche (27,4 %→29,1 %) progressent légèrement.

7.3 Groupes gagnants par commune




Figure 9 — Nombre de communes gagnées par groupe politique — Bretagne, 2017 vs 2022.

En nombre de communes remportées (sur 1 207 communes communes aux deux années), la bascule est encore plus marquée : la gauche, en tête en 2017 (447 communes), recule à 260 en 2022, tandis que l'extrême droite passe de 373 à 586 communes.

7.4 Matrice de corrélation




Figure 10 — Matrice de corrélation entre indicateurs socio-économiques et scores politiques.

La corrélation de Pearson entre les 8 indicateurs et les 5 scores politiques révèle deux axes structurants : un axe revenu (le revenu médian est corrélé à +0,66 avec le score du centre et à -0,40 avec l'extrême gauche — la corrélation la plus forte de l'analyse) et un axe éducation (le pourcentage de personnes sans diplôme est corrélé à +0,36 avec le score "droite", et le pourcentage de diplômés du supérieur à -0,41 avec l'extrême droite).

7.5 Indicateur le plus corrélé par groupe politique




Figure 11 — Indicateur le plus corrélé pour chaque groupe politique.

Pour chaque groupe politique, l'indicateur le plus déterminant a été identifié : revenu_median pour le centre (+0,66) et l'extrême gauche (-0,40) ; pct_diplome_sup pour la gauche (+0,41) et l'extrême droite (-0,41) ; pct_sans_diplome pour la droite (+0,36).

7.6 Distribution du revenu médian




Figure 12 — Distribution du revenu médian par commune.

L'indicateur le plus corrélé globalement (revenu_median, $r = 0,66$ avec le score centre) suit une distribution proche de la loi normale, centrée autour de 21 264 €, avec une variation de 13 420 € à 32 860 € selon les communes.

8. Modélisation prédictive

8.1. Définition du problème

L'objectif étant de prédire le résultat de 2022 à partir de la situation antérieure, les données ont été mises au format large : une ligne par commune (1 207 communes présentes lors des deux scrutins). La variable cible est le groupe gagnant en 2022, qui comporte trois modalités effectivement observées : extrême droite (586 communes), centre (361) et gauche (260). Le problème relève donc de la classification supervisée à trois classes.

Les 21 variables explicatives sont toutes connues avant le scrutin de 2022 : quatre indicateurs structurels (population, superficie, densité, vie associative), six indicateurs socio-économiques de 2016, les cinq scores de l'élection de 2017 (résultat précédent, cf. section 5.2) et six variables de tendance (delta), mesurant l'évolution de chaque indicateur entre 2016 et 2021. La cible (résultat 2022) n'apparaît jamais parmi les variables.

8.2. Principe de l'apprentissage supervisé

L'apprentissage supervisé consiste à entraîner un modèle à partir d'exemples dont la réponse (variable cible) est déjà connue. Le modèle reçoit des couples (variables explicatives, résultat). Ici, le profil d'une commune et le groupe arrivé en tête en 2022 et apprend les relations entre les deux. Une fois entraîné, il peut prédire le résultat de nouvelles communes dont on ne connaît que le profil. C'est la démarche suivie ici, en séparant les données en un jeu d'entraînement et un jeu de test.

8.3. Méthodologie d'apprentissage

Les données ont été séparées en 80 % d'entraînement (965 communes) et 20 % de test (242 communes), de manière stratifiée pour préserver la proportion des trois classes dans les deux ensembles (ext_droite $\approx$ 48,5 %, centre $\approx$ 29,8 %, gauche $\approx$ 21,5 %). Les variables ont été standardisées (le normalisateur étant ajusté uniquement sur l'entraînement, pour éviter toute fuite), et un poids équilibré (class_weight='balanced') a été appliqué pour compenser le déséquilibre des classes. La comparaison des modèles s'appuie sur une validation croisée à 5 plis, fournissant une performance moyenne et un écart-type mesurant la stabilité.

8.4. Comparaison des cinq modèles

Cinq algorithmes de classification, choisis pour leur diversité, ont été entraînés et comparés sur les mêmes données :

Modèle	Accuracy	F1 macro	Validation croisée
Gradient Boosting	0,802	0,784	0,755 ± 0,031
Random Forest	0,789	0,767	0,765 ± 0,018
Régression Logistique	0,789	0,785	0,744 ± 0,011
KNN	0,715	0,675	0,693 ± 0,027
SVM	0,702	0,691	0,744 ± 0,021




Figure 13 — Matrices de confusion des 5 modèles testés (jeu de test).




Figure 14 — Courbes d'apprentissage des 5 modèles testés.




Figure 15 — Courbes precision-recall (one-vs-rest) des 5 modèles testés.




Figure 16 — Courbe de perte (log-loss) du modèle Gradient Boosting.




Figure 17 — Importance des variables — Random Forest et Gradient Boosting.




Figure 18 — Synthèse comparative des 5 modèles (accuracy, F1 macro, validation croisée).

Les 5 modèles atteignent une accuracy comprise entre 70 % et 85 %. Les courbes d'apprentissage révèlent que Random Forest et Gradient Boosting présentent un écart important entre performance d'entraînement ($\approx 100\%$ et $97,7\%$) et validation croisée ($\approx 75-76\%$), signe de surapprentissage.

8.5. Choix du modèle final

Le modèle retenu est la Régression Logistique. Bien que Gradient Boosting affiche une accuracy légèrement supérieure (0,802 vs 0,789, soit environ 3 communes sur 242), la Régression Logistique présente :

- **Le meilleur F1 macro** (0,785, traitant les 3 classes à égalité)
- **La validation croisée la plus stable** (écart-type de 0,011, contre 0,031 pour Gradient Boosting)
- **Le plus faible écart** entre performance d'entraînement (0,771) et validation croisée (0,744) - un écart de 0,027, contre 0,222 pour Gradient Boosting (8 fois plus faible)

Ce dernier point est déterminant : un écart faible signifie que le modèle a appris une logique généralisable plutôt que mémorisé les exemples d'entraînement. Sa simplicité et son interprétabilité en font en outre un modèle plus facile à expliquer et à maintenir. Le choix privilégie ainsi la robustesse et la généralisation plutôt que la performance brute.

8.6. Résultats du modèle retenu et accuracy

Évaluée sur le jeu de test (242 communes jamais vues à l'entraînement), la Régression Logistique atteint une accuracy de 0,789 et un F1 macro de 0,785.

Pour contextualiser ce résultat :

- Une prédiction aléatoire entre 3 classes obtiendrait environ 33 % d'accuracy
- Une prédiction triviale (toujours prédire la classe majoritaire, `ext_droite`, présente dans 48,5 % des communes) obtiendrait environ 48,5 %
- Notre modèle atteint **78,9 %**, soit un gain de +30 points par rapport à la prédiction triviale




Figure 19 — Matrice de confusion du modèle final — Régression Logistique (jeu de test).

L'accuracy se définit comme la proportion de prédictions correctes parmi l'ensemble des prédictions : le nombre de communes dont le groupe gagnant a été correctement prédit, divisé par le nombre total de communes évaluées. Le F1 macro (0,785), qui traite les 3 classes à égalité (important car les classes sont déséquilibrées), confirme une performance équilibrée entre les groupes.

9. Scénarios prédictifs

Conformément au cahier des charges, le modèle final a été appliqué pour produire trois types de visualisations de scénarios, complétées par une carte de comparaison directe et une projection à 1, 2 et 3 ans.

9.1 Diagramme de probabilité




Figure 20 — Distribution des probabilités prédites par groupe politique.

La distribution des probabilités prédites pour chaque groupe sur les 1 207 communes montre une confiance moyenne du modèle de 77,6 % (médiane 80,3 %), signe d'un modèle généralement confiant dans ses prédictions.

9.2 Carte de chaleur




Figure 21 — Carte de chaleur — probabilité prédite de victoire de l'extrême droite, par commune.

La carte de chaleur représente, commune par commune, la probabilité prédite d'une victoire de l'extrême droite, avec une concentration au centre-est de la Bretagne — cohérente avec la carte réelle de 2022.

9.3 Courbes temporelles




Figure 22 — Évolution du pourcentage de communes gagnées par groupe — réel vs modèle.

En comparant le pourcentage de communes gagnées (2017 réel : 29,6 % / 2022 réel : 48,6 % / 2022 prédit : 42,6 % pour l'extrême droite), le modèle capture correctement la direction de la tendance électorale (hausse de l'extrême droite, baisse de la gauche), avec une légère sous-estimation de son ampleur.

9.4 Carte comparative réel vs prédit

Comparaison visuelle : resultat reel vs prediction du modele - 2022




Figure 23 — Carte comparative : résultat réel vs prédiction du modèle — 2022.

Une carte comparative directe entre le résultat réel de 2022 et la prédiction du modèle montre une forte similarité visuelle des grandes zones politiques, avec un taux de concordance global de 77,5 %.

9.5 Projection à 1, 2 et 3 ans

Pour répondre explicitement à la demande du cahier des charges de scénarios à 1, 2 et 3 ans, le modèle a été appliqué à une simulation d'accentuation progressive de la tendance socio-économique observée entre 2016 et 2021 (facteurs $\times 1,2$, $\times 1,4$, $\times 1,6$, en conservant inchangées les autres variables, notamment les scores de 2017). Cette projection montre une légère progression du centre (32,8 % $\rightarrow$ 39,5 %) et un léger recul de l'extrême droite (41,1 % $\rightarrow$ 36,7 %) sur l'horizon simulé.




Figure 24 — Scénario de projection à 1, 2 et 3 ans (accentuation progressive de la tendance observée).

Ce résultat doit être interprété avec prudence : il isole l'effet d'une poursuite de la tendance socio-économique locale, toutes choses égales par ailleurs sur le contexte électoral de référence (scores 2017 inchangés). Il suggère que la dynamique électorale nationale, davantage que l'évolution socio-économique locale seule, explique la progression de l'extrême droite observée entre 2017 et 2022 — un éclairage utile sur les leviers d'action réellement mobilisables à l'échelle locale. Cette projection reste une simulation basée sur une hypothèse de continuité, et non une prédiction certaine : une validation empirique nécessiterait des données électorales intermédiaires réelles (cf. section 11).

Cette méthodologie de restitution constitue la base transposable à de véritables scénarios prospectifs, dès lors que des données électorales intermédiaires réelles deviendront disponibles pour validation.

10. Réponses aux questions d'analyse

10.1. Quelle donnée est la plus corrélée aux résultats électoraux ?

Le revenu médian est l'indicateur le plus fortement corrélé aux résultats électoraux dans notre analyse, avec une corrélation de +0,66 avec le score du centre (et -0,40 avec l'extrême gauche) — la corrélation la plus forte observée sur l'ensemble des 8 indicateurs et 5 scores. Le niveau de diplôme constitue le second facteur déterminant : le pourcentage de diplômés du supérieur est corrélé à -0,41 avec le score de l'extrême droite et +0,41 avec celui de la gauche, tandis que le pourcentage de personnes sans diplôme est corrélé à +0,36 avec le score de la droite. Deux axes structurent ainsi le vote breton : un axe revenu (le plus discriminant) et un axe éducation.

10.2. Quel est le principe de l'apprentissage supervisé ?

L'apprentissage supervisé consiste à entraîner un modèle à partir d'exemples dont la réponse est déjà connue. Le modèle reçoit des couples (caractéristiques, résultat) — ici, les indicateurs d'une commune et le groupe qui y est arrivé en tête — et apprend les relations entre les deux. Une fois entraîné, il peut prédire le résultat de nouvelles communes dont on ne connaît que les caractéristiques. C'est la démarche suivie ici, en séparant les données en un jeu d'entraînement et un jeu de test.

10.3. Comment définir l'accuracy du modèle ?

L'accuracy est la proportion de prédictions correctes parmi l'ensemble des prédictions : le nombre de communes dont le groupe gagnant a été correctement prédit, divisé par le nombre total de communes évaluées. Le modèle atteint une accuracy de 0,789, c'est-à-dire qu'il prédit correctement le groupe gagnant dans environ 79 % des communes du jeu de test. Cette métrique est complétée par le F1 macro, qui tient compte du déséquilibre entre les classes.

11. Limites et perspectives

La preuve de concept présente plusieurs limites assumées, liées principalement à la profondeur temporelle des données disponibles plutôt qu'à des choix méthodologiques évitables.

Profondeur historique limitée

Le dataset ne couvre que deux scrutins présidentiels (2017 et 2022), soit un seul intervalle de cinq ans — contrainte du calendrier électoral français, et non un choix de notre part. Cette limite a un impact direct sur la section 9.5 : la projection à 1, 2 et 3 ans y est simulée (en supposant une poursuite de la tendance socio-économique observée), mais ne peut être validée empiriquement faute de données électorales intermédiaires réelles à ces horizons.

Poids de l'inertie électorale

Le recours aux scores de 2017 comme variable explicative, bien que légitime (ils sont antérieurs à 2022), confère une part importante à l'inertie électorale dans les prédictions du modèle — confirmé par l'analyse de l'importance des variables (section 8.4), où ces scores dominent largement. Le modèle reste néanmoins pertinent : le paysage politique a fortement évolué entre les deux scrutins (progression de l'extrême droite de 29,6 % à 48,6 % des communes), une dynamique que les seuls scores de 2017 ne pouvaient mécaniquement anticiper. La projection à 1/2/3 ans (section 9.5) éclaire d'ailleurs ce point : elle suggère que cette dynamique électorale nationale pèse davantage que l'évolution socio-économique locale seule.

Périmètre géographique unique

L'étude porte exclusivement sur la Bretagne ; la capacité du modèle à se généraliser à d'autres régions, avec des profils socio-économiques et des dynamiques politiques différents, n'a pas été testée.

Classes minoritaires non prédictibles

Les groupes “droite” et “extrême gauche”, absents des résultats 2022 (0 commune gagnée), ne peuvent être prédits par construction — une limite structurelle du contexte électoral observé, indépendante du modèle choisi.

Plusieurs pistes permettraient de renforcer le dispositif lors d'une phase de production : intégrer davantage de scrutins (européennes, municipales, régionales) pour gagner en robustesse temporelle et permettre une validation empirique des scénarios à 1/2/3 ans, descendre à une maille plus fine (bureaux de vote), enrichir le corpus (sondages, dépenses publiques locales), étendre l'étude à d'autres régions pour tester la généralisation du modèle, et industrialiser le pipeline pour des prévisions prospectives validées empiriquement à un, deux et trois ans, sur la base de données électorales intermédiaires réelles.

12. Conclusion

Cette preuve de concept démontre qu'il est possible de prédire le groupe politique arrivé en tête dans une commune à partir de sa situation socio-économique et de son historique électoral, avec une fiabilité de 78,9 % — soit 30 points au-dessus de la prédiction triviale. La chaîne de traitement mise en place, de la collecte des données brutes jusqu'aux scénarios de restitution, est entièrement documentée et reproductible, et les livrables (jeu de données nettoyé et normalisé, base SQL, code commenté, visualisations) sont directement exploitables. Le dispositif valide ainsi l'approche d'Electio-Analytics et constitue une base solide pour une mise à l'échelle et d'éventuelles demandes de financement.